



Máster en Data Analytics & Data Science

Proyecto Júpiter

Guion de proyecto

Introducción

El **Proyecto Júpiter** constituye el **Trabajo de Fin de Máster (TFM)** del Máster en Data Analytics & Data Science, y representa el final del recorrido académico del estudiante. La correcta ejecución y desarrollo de este proyecto son fundamentales para la obtención del título.

Este trabajo se desarrollará en **equipos compuestos por entre 3 y 5 personas**. La colaboración efectiva, la distribución equilibrada del trabajo, así como la aportación individual, serán elementos clave tanto en la ejecución como en la evaluación del proyecto.

A lo largo del Proyecto Júpiter, los estudiantes deberán demostrar no solo los conocimientos técnicos adquiridos durante el Máster, sino también habilidades de comunicación, gestión de proyectos, trabajo en equipo y pensamiento crítico.

Objetivo del trabajo

El objetivo principal del Proyecto Júpiter es el **diseño, desarrollo e implementación de una solución de Data Analytics y Data Science**, partiendo desde un conjunto de datos no estructurados dado, hasta la entrega de una solución funcional, documentada y evaluada de forma profesional.

A grandes rasgos, cada equipo deberá:

- Analizar y entender el **caso de uso elegido** en el que una solución de Data Analytics y Data Science aporte valor, comprendiendo las necesidades a cubrir y los requisitos de negocio.
- Diseñar y desarrollar un **modelo de datos relacional** que facilite y eficiente el almacenamiento, extracción y análisis del dato.
- Diseñar y calcular **métricas y KPIs** relevantes para el negocio.
- Identificar **patrones de errores e incidencias** en los datos proporcionados.
- **Automatizar un proceso** mediante algoritmos de predicción.
- Diseñar e implementar una solución de **IA Generativa** para la optimización de un proceso que aporte valor al negocio.
- Diseñar y desarrollar cuadros de mandos (**dashboards**) que reflejen los KPIs y métricas estudiadas, así como que presenten los resultados con los principales drivers del problema y su análisis.
- Elaborar una **memoria técnica y de negocio** completa que refleje todo el proceso del proyecto, desde su concepción hasta su ejecución final.

Este trabajo es una oportunidad para consolidar los conocimientos adquiridos durante el Máster, y para demostrar la capacidad de aplicar la analítica y ciencia de datos a problemas del mundo real, con una perspectiva técnica, estratégica y colaborativa.

Elección y análisis del caso de uso

Adjunto a este guion de proyecto, cada equipo recibirá un conjunto de distintos casos de uso entre los que debe seleccionar uno de ellos, sin que sea posible seleccionar un caso de uso que ya haya sido elegido por otro equipo de esa misma edición del Máster. Cada caso de uso incluirá:

- Una introducción de negocio que presenta el contexto técnico y funcional del problema a resolver
- Una descripción del problema a resolver
- Detalle de los distintos conjuntos de datos que incluirá el caso de uso
- Un listado de métricas y KPIs para su cálculo
- Un listado de reglas de negocio para la identificación de errores e incidencias
- Una descripción del proceso a automatizar con algoritmos predictivos

Además, se incluirán todos los ficheros de datos requeridos para la elaboración del proyecto. Estos vendrán dados en un formato no estructurado que requerirá del análisis, limpieza y extracción por parte de cada equipo.

Modelo de datos relacional

El objetivo de esta tarea es diseñar e implementar un modelo de datos relacional que permita almacenar los datos del caso de uso facilitados, monitorizarlos y calcular ciertas métricas de negocio que permitan analizar los datos e información de la compañía. Para desarrollar este modelo, se exige utilizar tecnologías SQL.

En el modelo de datos relacional diseñado se evaluará la eficiencia en el almacenamiento y procesamiento a la hora de acceder a los datos, así como la correcta aplicación del tipado de datos, relaciones entre tablas del esquema y propiedades de cada uno de los campos (*nullable*, *default*, *value*, *primary key*, *foreign key*, ...). De manera opcional, se valorará positivamente la identificación y uso de las formas normales de bases de datos para este diseño e implementación del esquema de datos relacional.

Esta tarea tiene como objetivo la entrega de:

- **Esquema relacional:** diagrama de relación de las distintas entidades del modelo junto con sus campos y tipos de datos. Este diagrama debe entregarse en un formato de imagen válido (*.jpeg*, *.png*, ...).
- **Script SQL:** un único archivo que incluya todas las sentencias SQL utilizadas a lo largo de todo el proceso de implementación del esquema relacional: creación, modificación y actualización de tablas y vistas, inserciones en tablas, procesamiento de archivos, ...

Por último, será necesaria la carga de todos los datos en el esquema relacional. Para ello se podrá utilizar cualquier método elegido por el equipo: programáticamente a través de código en Python o SQL, mediante el uso de herramientas como *Import Wizard* de MySQL, ... Será importante, a la hora de elaborar la memoria, detallar cómo se llevó a cabo este proceso.

Métricas y KPIs

En cada caso de uso se incluirá un listado de las métricas y KPIs que el equipo debe calcular obligatoriamente. **Estos cálculos deben realizarse utilizando tecnologías SQL**, pudiendo, de manera opcional, ser corroborados llevando a cabo el mismo cálculo con otras tecnologías, como el lenguaje de programación Python. La entrega de este objetivo se realizará a través de un script SQL (diferente al mencionado en la tarea del modelo de datos relacional) en el que deben incluirse:

- Todas las sentencias SQL utilizadas para resolver el cálculo de cada KPI
- El enunciado del KPI en forma de comentario precediendo a su sentencia SQL
- El resultado obtenido en forma de comentario después de la sentencia SQL que los calcula
- Nombre/s de la/s persona/s que haya implementado la sentencia. Este nombre debe incluirse en forma de comentario tras el comentario que incluye el resultado (mencionado en el punto anterior) escribiendo: *Resuelto por <nombre del alumno/s>*

Para poder aprobar el Proyecto Júpiter, **el equipo deberá repartir equitativamente el listado de métricas y KPIs entre todos sus miembros**. Cada alumno deberá resolver individualmente, al menos, el número resultante de dividir el total de preguntas entre los miembros del equipo (redondeando hacia abajo); siendo obligatorio que todas las preguntas queden resueltas. Es requisito indispensable la resolución, por parte de cada alumno, de sus preguntas correspondientes.

Para evaluar este apartado, no solo se tendrá en cuenta el haber alcanzado un **resultado final correcto**, sino también la **eficiencia y claridad de cada una de las sentencias** desarrolladas para llegar al mismo. Además, se valorará positivamente el planteamiento y resolución de otras métricas y KPIs que aporten valor funcional y/o técnico al caso de uso elegido.

Identificación de patrones de errores e incidencias

Este objetivo consiste en identificar posibles datos erróneos o incompletos que se encuentren entre los proporcionados. Con el fin de lograrlo, será necesario aplicar el conocimiento que se tiene del negocio, así como las reglas de negocio que se incluyen en el documento descriptivo del caso de uso correspondiente. Cada equipo tendrá que:

- Comprobar si se cumplen o no cada una de las **reglas de negocio** proporcionadas. En caso de no cumplirse deberá indicarse la cantidad de casuísticas en las que sí y en las que no se sigue con la regla de negocio. Pueden existir reglas de negocio que no se cumplen en ningún caso.
- **Complejidad del dato**: Identificar valores faltantes (*NaN*, *null*, blancos, ...), analizarlos, y proponer una estrategia de limpieza de estos datos: rellenarlos, eliminar ciertos registros o dejarlos como se facilitan inicialmente. Esta estrategia debe estar justificada con las observaciones vistas en el EDA (análisis exploratorio de datos) que debe llevarse a cabo.
- **Duplicidad**: revisar si existen registros repetidos que podrían distorsionar el análisis, analizarlos y proponer una estrategia de limpieza de estos datos. Esta estrategia debe estar justificada con las observaciones vistas en el EDA que debe llevarse a cabo.
- **Consistencia de formatos**: revisar la existencia de inconsistencias de formato en los datos (columnas con tipos de datos diferentes, fechas en distintos formatos, unificación de valores iguales escritos diferentes, ...), analizarlos y aplicar una estrategia de limpieza de datos. Esta

estrategia debe estar justificada con las observaciones vistas en el EDA que debe llevarse a cabo.

- **Rangos y valores atípicos:** identificación de existencia de rangos de valores erróneos. Deben distinguirse aquellos valores que sean erróneos (como una edad negativa) de valores extremos válidos pero infrecuentes (*outliers* legítimos). Tras su identificación deben analizarse y proponer una estrategia de limpieza de estos datos. Esta estrategia debe estar justificada con las observaciones vistas en el EDA que debe llevarse a cabo.
- **Homogeneidad de unidades y escalas:** identificar si existen medidas en diferentes unidades o escalas, analizarlas y proponer una estrategia de limpieza de estos datos. Esta estrategia debe estar justificada con las observaciones vistas en el EDA que debe llevarse a cabo.
- **Relevancia de variables:** identificar campos redundantes o irrelevantes (columnas que no aportan al análisis y puedan eliminarse) y/o correlaciones fuertes.
- **Detección de sesgos:** evaluar si hay sobre-representación o infra-representación de algún grupo período o categoría y revisar si faltan registros que pudieran distorsionar las conclusiones.
- **Consistencia del dato:** verificar si existen contradicciones entre las diferentes variables, analizarlas y proponer una estrategia de limpieza de estos datos. Esta estrategia debe estar justificada con las observaciones vistas en el EDA que debe llevarse a cabo.

Para la realización de esta tarea se deberá utilizar el lenguaje de programación Python, entregando uno o varios Notebooks en los que se ejecuten y se expliquen detalladamente cada una de las operaciones necesarias para todas estas comprobaciones. Para su evaluación, se tendrá en cuenta no solo la resolución de cada uno de los puntos anteriores, sino también la eficiencia y claridad del código entregado, así como la documentación y explicaciones presentadas en los Notebooks.

Automatización mediante algoritmos de predicción

Cada caso de uso describe detalladamente la automatización de un proceso mediante el uso de algoritmos de predicción. Para resolverlo, deben seguirse los siguientes pasos:

1. Opcionalmente, si se ve necesario, recopilar y unificar los datos necesarios para el problema en un único dataset.
2. Identificar las conclusiones del EDA útiles para la selección de los datos y el algoritmo.
3. Efectuar las tareas de limpieza del dataset requeridas (por ejemplo, tratamiento de valores nulos para algoritmos que no los permitan).
4. Si se requiere, utilizar técnicas de data augmentation.
5. Identificar el problema y los objetivos.
6. Selección de las métricas y umbrales.
7. Fase de selección de datos.
8. Selección del algoritmo predictivo.
9. Entrenamiento y parametrización del algoritmo de aprendizaje.
10. Evaluación del modelo.

Para poder aprobar el Proyecto Júpiter, es necesario que **cada alumno** lleve a cabo los pasos 7-10 para, **como mínimo, dos algoritmos de aprendizaje** de los cuales uno debe pertenecer al ámbito del Deep Learning y otro no. Téngase en cuenta que no es necesario que se obtengan buenos resultados en las métricas elegidas, ya que la dificultad y el resultado esperado varía en cada caso

de uso. Tras esto, el equipo deberá crear una tabla comparativa en la que se presenten todos los modelos entrenados con sus evaluaciones.

Para la corrección, será necesario entregar uno o varios archivos en los que se registren todas las operaciones realizadas y sus salidas (puede ser un Jupyter Notebook, Google Colab u otro tipo de presentación en el que se pueda ver tanto el código como el resultado de su ejecución), así como la tabla comparativa de los modelos (el formato de entrega de esta tabla es a elección del equipo). Es preferible, que para poder obtener los mismos resultados si se vuelve a ejecutar, se fije una semilla aleatoria en los distintos algoritmos.

Para la evaluación de este apartado, se tendrá en cuenta no solo la evaluación de los distintos modelos, sino también la eficiencia, claridad y buenas prácticas del código entregado, así como la documentación y explicaciones presentadas en los Notebooks.

Solución de IA Generativa

Además de los objetivos que se busca resolver con analítica y ciencia de datos, se incluye la tarea de buscar cómo optimizar y mejorar la eficiencia de procesos relacionados con el caso de uso elegido utilizando tecnologías de IA Generativa. Para ello, se deben identificar posibles aplicaciones sobre los que poner en funcionamiento esta tecnología, proponer una arquitectura que aborde estos casos de uso e implementar un código de prueba que permita mostrar la viabilidad del caso. Para este hito, deben justificarse los casos de uso elegidos con métricas y detallar lo máximo posible la solución técnica propuesta.

Para la corrección de este apartado, será necesario entregar un documento en el que se detallen los casos de uso y se describa la solución técnica planteada. Por otro lado, también se espera la entrega de uno o varios archivos en los que se registre todo el código desarrollado en Python y sus salidas (puede ser un Jupyter Notebook, Google Colab u otro tipo de presentación en el que se pueda ver tanto el código como el resultado de su ejecución).

Herramientas y recursos complementarios

Para la ejecución del proyecto se deben utilizar las siguientes herramientas:

- **MySQL:** como herramienta y lenguaje para el trabajo con bases de datos relacionales.
- **Python:** como lenguaje de programación para la implementación de todos los objetivos que lo requieran.
- **PowerBI:** como herramienta para el desarrollo del Dashboard a entregar.

Por otro lado, se facilitan los siguientes recursos complementarios por si sirviera de ayuda al estudiante:

- Documentación de Scikit-Learn: <https://scikit-learn.org>
- Documentación de MySQL: <https://www.mysql.com/>
- Documentación de Tensorflow: <https://www.tensorflow.org>
- Documentación de Keras: <https://keras.io/>

Entregables

Cada equipo deberá entregar la siguiente documentación y materiales:

1. **Modelos de datos relacional:**
 - a. Esquema relacional: diagrama de relación de las distintas entidades del modelo junto con sus campos y tipos de datos. Este diagrama debe entregarse en un formato de imagen válido (.jpeg, .png, ...).
 - b. Script SQL: un único archivo que incluya todas las sentencias SQL utilizadas a lo largo de todo el proceso de implementación del esquema relacional: creación, modificación y actualización de tablas y vistas, inserciones en tablas, procesamiento de archivos, ...
2. **Métricas y KPIs:**
 - a. Script SQL: con la resolución de todos los KPIs (formato establecido en el apartado correspondiente). Si se proponen KPIs o métricas adicionales se deben incluir también en este script.
 - b. Comprobación de resultados (opcional): opcionalmente puede entregarse código Python con la comprobación de los resultados obtenidos en el script anterior.
3. **Archivos ejecutables:** independientemente del tipo (Jupyter Notebook, Google Colab u otros) deben entregarse los archivos que puedan ejecutarse para comprobar los resultados de código obtenidos en cada uno de los objetivos detallados anteriormente.
4. **Solución de IA Generativa:** documento que recoja los casos de uso y la solución técnica planteadas con herramientas de IA Generativa.
5. **Memoria del proyecto:** documento resumen del proyecto (en él no se debe plasmar todos los detalles ni el código ejecutado) que exponga (el informe no debe superar las 20 páginas) los siguientes apartados:
 - a. Introducción y resumen ejecutivo del proyecto.
 - b. Contribución individual de cada miembro del equipo (se debe especificar claramente quién ha contribuido con qué).
 - c. Modelo relacional: en él se debe exponer el modelo relacional diseñado e implementado (puede hacerse uso del esquema solicitado).
 - d. EDA e identificación de errores: exposición de las conclusiones del EDA y del proceso de identificación de errores y limpieza de datos llevado a cabo.
 - e. Automatización de proceso: detalle y conclusiones de la resolución del objetivo de automatización del proceso mediante algoritmos de predicción.
 - f. Conclusiones finales y trabajo futuro.
6. **Dashboard:** se deben diseñar cuadros de mandos en PowerBI que reflejen los KPIs estudiados y que presenten los resultados con los principales drivers del problema, su análisis y la propuesta de su mejora o solución.

Evaluación

La evaluación se realizará de forma **individualizada**, aunque el proyecto sea desarrollado en equipo. Cada estudiante será evaluado en función de su **contribución específica** al proyecto, su comprensión global del mismo y su participación en la presentación final.

La ponderación total del trabajo consistirá en la evaluación de los entregables descritos anteriormente (que representan el 60% de la nota final del Proyecto Júpiter) y el desempeño en la presentación final (que representa el 40% de la nota final).

El cálculo del 60% de la nota referente a los entregables, se desglosa de la siguiente forma:

- KPIs y métricas: 10%
- Automatización con algoritmos de predicción: 30%
- Resto de apartados: 20%

Por otro lado, para el 40% relacionado con la presentación final se valorará la **claridad, estructura, dominio del tema y coherencia** en la exposición. Todos los miembros del equipo deberán participar activamente en la presentación que tendrá una duración de 5 minutos por cada miembro del equipo (no pudiendo superar este límite individualmente cada alumno, en caso de superarlo, podría interrumpirse la presentación). Se evaluará la **capacidad de argumentar decisiones**, responder a las preguntas planteadas al finalizar y justificar la aportación individual.

Conclusión

El Proyecto Júpiter representa una oportunidad para aplicar todo lo aprendido en el Máster en un entorno práctico, creativo y colaborativo. Este trabajo es una carta de presentación para el mundo profesional, por lo que se espera el máximo compromiso, seriedad y excelencia por parte del alumnado.

La clave del éxito residirá en la **colaboración efectiva**, la **organización del equipo**, y la **capacidad de convertir una idea en una solución técnica y de negocio sólida**.